Base de datos de vivienda Dils

Documentación resumida · fase 1

Generado el 29/10/2026 desde el repositorio del proyecto

Contenido: 1. Qué es · 2. Tablas · 3. Cómo se usa · 4. Pendiente de decisión · 5. Prototipos · 6. Glosario

1. Qué es

Un proceso en Python (ETL) que descarga estadísticas públicas de vivienda de España, sobre todo del Ministerio de Vivienda (MIVAU), las limpia y las deja todas con el **mismo formato**: territorio con códigos INE, periodo, fecha real y una clave única por fila. Con eso genera:

- **Los datos completos** de cada tabla en CSV (`etl/salida/`), listos para importar a MySQL.
- **El SQL**: `sql/create_tables.sql` (crea las tablas) y `sql/load_data.sql` (las carga).
- **El Excel** `Data Dils_v2.xlsx`: catálogo de tablas con su `CREATE TABLE`, diccionario de campos, maestro de territorios, glosario y una muestra de 1.000 filas de cada tabla (hojas ocultas).
- **La documentación**: `docs/README.md`, una ficha por fuente en `docs/fuentes/` y el registro de decisiones `docs/decisiones.md`.

Formato común de todas las tablas: **periodo** 2026M06 / 2026T2 / 2026 · **fecha** AAAA-MM-DD (primer día del periodo) · **territorio** ES, CAxx, PRxx, MUxxxxx, DIxxxxxxx, SCxxxxxxxxxx · **anio, trimestre, mes** calculados por MySQL a partir de la fecha.

2. Tablas con datos

12 tablas en el esquema MIVAU. El detalle de cada campo está en la hoja Campos del Excel y el origen y las transformaciones en la ficha de cada fuente.

Tabla	Fuentes (boletín)	Frecuencia	Filas
mivau_vpo_calificaciones_definitivas	31205000	Mensual	15.984
mivau_vivienda_libre_iniciadas	32100500	Mensual	15.984
mivau_vivienda_libre_terminadas	32101000	Mensual	15.984
mivau_eti_transacciones	34010110 + ETI (34010120-34010190)	Trimestral	58.320
mivau_eti_compradores_extranjeros	340101g0	Trimestral	37.050
mivau_valor_medio_vivienda_libre	34020150, 34020160, 34020170, 34020180	Trimestral	25.920
mivau_valor_tasado_vivienda_libre	35101000, 35101500, 35102000	Trimestral	18.448
mivau_valor_tasado_municipios_25000	35103500	Trimestral	63.610
mivau_precio_suelo_urbano	36400500	Trimestral	6.120
mivau_certificados_fin_obra	BOL09-FINOBRA	Mensual	2.912
mivau_visados_direccion_obra	BOL09-VISADOS	Mensual	2.912
mivau_serpavi_alquiler	SERPAVI	Anual	1.281.664 (CSV local, no versionado)

Sin datos por ahora: el índice de costes de construcción (columnas sin rótulo en el archivo) y las fuentes del Notariado e Idealista (aplazadas).

3. Cómo se usa

Para…	Ejecutar (desde la carpeta del proyecto)
Instalar	`python -m pip install -r requirements.txt`
Descargar y regenerar todo (~10 min)	`python -m etl.ejecutar_todo`
Regenerar una sola fuente	`python -m etl.ejecutar_todo MIVAU-31205000`
Rehacer solo el Excel	`python -c "from etl.construir_libro import construir_libro; construir_libro()"`
Regenerar el SQL	`python -m etl.catalogo.sql`
Crear las tablas en MySQL	`mysql --local-infile=1 -u USUARIO -p < sql/create_tables.sql`
Cargar los datos	`mysql --local-infile=1 -u USUARIO -p < sql/load_data.sql`
Comprobar que todo está bien (~8 min)	`python -m pytest`

- Volver a cargar **actualiza** las filas existentes (REPLACE); las que la fuente deja de publicar no se borran.
- El CSV de SERPAVI (1,3 millones de filas) no está en GitHub por tamaño: se genera con `python -m etl.ejecutar_todo MIVAU-SERPAVI`.
- Tu Excel original `Data Dils.xlsx` solo se lee; nunca se modifica.
- No ejecutar `python -m etl.catalogo.sembrar`: sobrescribiría el catálogo (está protegido).

4. Pendiente de tu decisión

Cada punto está explicado en la ficha de su fuente y en docs/decisiones.md.

- **Ceuta y Melilla como agregado en** `340101g0` (compradores extranjeros): la fila de vivienda "Ceuta y Melilla" no se carga y se pierden sus cifras; ES no es la suma de las comunidades cargadas.
- **Ceuta y Melilla en** `34020180` (valor medio, extranjeros residentes): se omite el agregado, no sus partes.
- **Ceros de** `34020180`: 4 ceros literales (vivienda nueva de Zamora 2022T3/T4 y Albacete 2024T2/T3) cargados como 0; probablemente significan "sin operaciones".
- **Ceuta y Melilla en** `35101000/1500/2000` (valor tasado): se omite el agregado; sus valores por separado sí se cargan.
- `MIVAU-57010000` (índice de costes): `solo_diseno`; hay que confirmar los nombres de las 13 columnas, sin rótulo en el archivo.
- `BOL09-FINOBRA`: rótulos de columna tomados de una imagen incrustada, no de texto del archivo.
- `BOL09-VISADOS`: rótulos de columna tomados de una imagen incrustada.
- **Boletines ETI no cargados** (tipología del edificio, residencia del comprador, valor y superficie, etc.): decidir si interesan.
- **ETI, 18 diferencias en las sumas de la rejilla** régimen x antigüedad (lista cerrada `EXCEPCIONES_IDENTIDADES`), cargadas tal cual.
- **SERPAVI, fila 21 de la hoja CCAA** (total nacional sin etiqueta, solo recuentos): decidir si se carga como ES.
- **SERPAVI, 35 diferencias de recuento entre niveles**, todas en Navarra, cargadas tal cual.
- **Tarea 15 aplazada** (Notariado e Idealista): `NOT-NP-MENSUAL`, `NOT-PEN`, `IDEALISTA-ALQUILER` e `IDEALISTA-VENTA` siguen en `solo_diseno`, sin esquema, tabla ni ficha; el usuario indicó que no interesan por ahora. Si se retoman, Idealista probablemente prohíbe la extracción automática y la vía sería su acceso oficial (decisión del 2026-10-29).
- **Validación de la sintaxis MySQL pendiente**: no hay servidor MySQL ni MariaDB en la máquina, así que `sql/create_tables.sql` y `sql/load_data.sql` no se han ejecutado contra uno real.

- `Libro1.xlsx`: copia antigua sin versionar en la raíz; preguntar al usuario antes de borrarla.

5. Prototipos (por decidir)

Están en la carpeta prototipos/ y no afectan a lo que ya funciona. Para pasarlos a producción hay que responder estas preguntas:

Maestros como tablas MySQL y relaciones

- ¿FK reales o solo documentadas?
- ¿Esquema `MAESTROS` aparte o cada maestro dentro de cada esquema?
- ¿Se incluyen secciones censales y distritos?
- ¿`dim_categoria` genérica o una tabla por categoría?
- ¿Códigos INE de municipio versionados por año?

Mapeo origen → destino y control de cargas

- ¿El mapeo se mantiene a mano o se genera?
- ¿Dónde vive `META`?
- ¿Se guardan los archivos originales (por hash) para auditoría?
- ¿Se guarda el historial de revisiones?

6. Glosario

Término	Definición
VPO	Vivienda de protección oficial: vivienda sujeta a un régimen de protección pública (precio y destinatarios limitados). En el proyecto, la tabla mivau_vpo_calificaciones_definitivas cuenta las calificaciones definitivas de planes estatales y autonómicos.
Calificación definitiva	Acto administrativo que declara que una vivienda protegida terminada cumple los requisitos del régimen de protección. El boletín MIVAU 31205000 cuenta el número de viviendas con calificación definitiva por mes.
Vivienda libre	Vivienda sin régimen de protección pública; su precio lo fija el mercado. Es el valor LIBRE de la dimensión regimen en las tablas ETI.
Vivienda protegida	Vivienda sujeta a un régimen de protección pública (VPO y equivalentes autonómicos). Es el valor PROTEGIDA de la dimensión regimen en mivau_eti_transacciones.
ETI	Estadística de Transacciones Inmobiliarias del MIVAU: compraventas de vivienda formalizadas ante notario, por territorio y trimestre. Alimenta mivau_eti_transacciones, mivau_eti_compradores_extranjeros y mivau_valor_medio_vivienda_libre.
Valor medio	Valor medio de las transacciones de vivienda libre, en euros por vivienda (no por m2), de la ETI. Columna valor_medio_eur de mivau_valor_medio_vivienda_libre.
Valor tasado	Valor medio de tasación de la vivienda libre en euros por m2, de las tasaciones (estadística de valor tasado del MIVAU). Columna valor_tasado_eur_m2. No es lo mismo que el valor medio de las transacciones (euros por vivienda).
Valor medio frente a valor tasado	El valor medio sale de compraventas reales (ETI, euros por vivienda); el valor tasado sale de tasaciones de vivienda (euros por m2). Son series distintas, en tablas distintas, y no deben compararse directamente.
Precio de suelo urbano	Precio medio del metro cuadrado de suelo urbano (euros/m2), trimestral por CCAA y provincia. Tabla mivau_precio_suelo_urbano; columna precio_eur_m2.
Certificado de fin de obra	Certificación del técnico director de que una obra de edificación está terminada. El boletín 09011600 cuenta las viviendas con certificado de fin de obra por promotor, mensual y nacional (mivau_certificados_fin_obra).
Visado de dirección de obra	Visado colegial del proyecto o dirección de una obra de edificación (obra nueva, ampliación o reforma). El boletín 09010600 cuenta viviendas y superficie media por tipo de obra, mensual y nacional (mivau_visados_direccion_obra).
Precio asking	Precio de oferta publicado en un anuncio, no el precio de la operación cerrada. Es la medida de los informes de Idealista; esas fuentes están catalogadas como solo_diseno y no se cargan.
SERPAVI	Sistema Estatal de Referencia del Precio del Alquiler de Vivienda del MIVAU. Rentas de alquiler de vivienda habitual (explotación de datos tributarios del IRPF cruzados con el Catastro), anuales 2011-2024. Tabla mivau_serpavi_alquiler.
Renta mediana	Valor central de las rentas de alquiler de un territorio y año (la mitad de los inmuebles paga menos). SERPAVI da también los percentiles 25 y 75 (p25, p75). Las medianas no se suman entre territorios.
Testigos	Inmuebles o contratos observados para calcular una estadística. En SERPAVI el recuento (num_inmuebles_alquiler) cuenta bienes inmuebles con ingresos por arrendamiento de vivienda habitual, no contratos ni testigos.
Sección censal	Unidad territorial mínima del seccionado del Censo de Población 2021 del INE. Código SC + 10 dígitos (provincia, municipio, distrito, sección). Solo aparece en mivau_serpavi_alquiler.
Distrito	Subdivisión de un municipio formada por varias secciones censales (seccionado del Censo 2021). Código DI + 7 dígitos. Solo aparece en mivau_serpavi_alquiler.
Uniprovincial	Comunidad autónoma con una sola provincia (Madrid, Asturias, Baleares, Cantabria, Murcia, Navarra, La Rioja, Ceuta y Melilla). Si la fuente solo trae la fila de la comunidad, el proyecto genera la de provincia copiándola.
Código ES	cod_territorio del total nacional: ES.
Código CA	cod_territorio de una comunidad autónoma: CA + código INE de 2 dígitos (p. ej. CA10). Sale de Maestro Territorios.
Código PR	cod_territorio de una provincia: PR + código INE de 2 dígitos (p. ej. PR04).
Código MU	cod_territorio de un municipio: MU + código INE de provincia (2 dígitos) y municipio (3 dígitos), 5 en total (p. ej. MU28079). Relación de municipios del INE a 1-1-2026.
Código DI	cod_territorio de un distrito: DI + 7 dígitos (provincia, municipio y distrito del seccionado 2021).

Término	Definición
Código SC	cod_territorio de una sección censal: SC + 10 dígitos (provincia, municipio, distrito y sección del seccionado 2021).
Formato de periodo	periodo se escribe AAAAMmm si es mensual (2026M06), AAAATn si es trimestral (2026T2) y AAAA si es anual (2024). frecuencia vale M, T o A. fecha es el primer día del periodo (AAAA-MM-DD).
Valores de nivel	nivel indica el nivel territorial de la fila: Nacional, CCAA, Provincia o Municipio; solo en mivau_serpavi_alquiler también Distrito y Seccion.
Columnas generadas	anio, trimestre y mes no se cargan: MySQL las calcula desde fecha y frecuencia (GENERATED ALWAYS AS ... STORED). Los CSV las conservan; load_data.sql las descarta. En el catálogo se marcan en la columna generado.
Provisional	provisional vale 1 cuando la fuente marca el dato como provisional y 0 en los demás casos (también cuando la fuente no lo indica).
fecha_descarga	Día en que se ejecutó el proceso que obtuvo el dato; igual en todas las filas de una carga. Una nueva carga reemplaza el valor anterior (UPSERT).
id_registro	Clave natural de cada fila: cod_territorio + dimensiones propias en el orden de Campos + periodo, unidos con _ (p. ej. PR04_TOTAL_2026M06). Es estable entre descargas.
Muestra del libro	Las hojas de datos de Data Dils_v2.xlsx (ocultas) son una muestra de como mucho 1.000 filas por tabla, con una nota en A1. La tabla completa está en etl/salida/<tabla>.csv y la columna Filas de la hoja Tablas da el total.
Estado con_datos	Dataset descargado, transformado y cargado en su tabla, con CSV en etl/salida/.
Estado solo_diseno	Dataset catalogado y, si procede, con tabla y campos diseñados, pero sin carga de datos (MIVAU-57010000 y los cuatro de Notariado e Idealista).
Estado pendiente	Valor previsto de la columna estado para un dataset aún sin tratar. Ningún dataset lo tiene en la entrega de la fase 1.